



# SLM – Small Language Model

## Pré-treino do Zero ao Chat

Deep Learning II – PUCRS 2026/1 · Lucas Vizzotto




# Arquitetura e Decisões de Design

**Base:** LlamaForCausalLM — decoder-only transformer, ~101.5M parâmetros. Weight tying (embedding compartilhado com lm\_head) reduziu de 140M → 101.5M.

| Componente          | Escolha               | Motivo                                           |
|---------------------|-----------------------|--------------------------------------------------|
| Atenção             | GQA (12Q / 4KV heads) | Reduz KV-cache 3× sem perda de qualidade         |
| Positional Encoding | RoPE                  | Melhor generalização que sinusoidal              |
| Ativação            | SwiGLU                | Supera GELU em escala                            |
| Normalização        | RMSNorm pre-norm      | Estabiliza gradientes, mais rápido que LayerNorm |


# Scaling Laws e Pipeline de Treino

**Chinchilla:** tokens ótimos  $\approx 20 \times$  parâmetros  $\rightarrow 101.5\text{M} \times 20 \approx 2\text{B tokens}$ . Treinamos com **4B tokens (2× o ótimo)** – estratégia do LLaMA 1: modelo menor treinado por mais tempo é mais eficiente em inferência.



# Resultados da Avaliação

Perplexidade (FineWeb-Edu, menor = melhor)



Salto no SFT é artefato de distribuição — o modelo passou a esperar formato chat. PPL em texto bruto não é métrica válida pós-SFT.

HellaSwag — Commonsense Reasoning

**Pré-treino**

28%

**Mid-Training**

30%

**SFT**

**34%** — acima do GPT-2 117M

Baseline aleatório = 25%.



# Discussão

## O que funcionou

- Pipeline completo do zero ao chat em recursos limitados (2× A5000)
- HellaSwag superou GPT-2 de tamanho similar

## O que mudaria com mais tempo/recursos

- Concluir o SFT (crashou em 200/500 steps por disk quota)
- Mais steps de mid-training com dataset maior



# Demo ao Vivo

Modelo: lds29/slm-sft

## Interface Streamlit

Parâmetros ajustáveis em tempo real: Temperature · Top-k · Top-p · Max new tokens

## Contexto de Conversa

O histórico completo da conversa é concatenado no prompt a cada turno — contexto de até 1024 tokens.

